

PRÉDICTION DE LA TOXICITÉ MOLÉCULAIRE PAR IA

Projet de Machine Learning / Tox21 – Chimioinformatique et modèles explicables

Faculté des Sciences Ben M’Sick
Master Intelligence Artificielle

Réalisé par : ERFOUDI Anass JOUNAIDI Oussama

Encadrante : GUENDOUL Oumaima

INTRODUCTION / CONTEXTE

La toxicologie expérimentale est coûteuse et difficile à appliquer à grande échelle. Ce projet utilise Tox21 pour prédire la toxicité de molécules à partir de leur structure SMILES.

- Prédiction *in silico* avant les tests biologiques.
- Représentations moléculaires avec RDKit.
- Modèles ML, ToxNet et explicabilité SHAP.

PROBLÉMATIQUE

- Identifier rapidement les molécules potentiellement toxiques.
- Gérer des labels incomplets et un fort déséquilibre.
- Obtenir une prédiction performante et interprétable.
- Transformer le modèle en prototype API + interface web.

OBJECTIFS DU PROJET

- Nettoyer et analyser le dataset Tox21.
- Calculer descripteurs RDKit et empreintes Morgan ECFP4.
- Entraîner des modèles sur la cible NR-AhR.
- Comparer ROC-AUC, PR-AUC, F1, rappel et précision.
- Expliquer avec SHAP; déployer via FastAPI/Streamlit.

DATASET ET PRÉTRAITEMENT

- 7 831 molécules chimiques.
- 7 823 molécules valides après filtrage RDKit.
- 12 essais biologiques Tox21.
- Tâche cible : NR-AhR.
- Classe positive rare : 13,3 %.
- Split stratifié et validation croisée.





Figure. Distribution des classes par essai Tox21.

MÉTHODOLOGIE



- Prétraitements ajustés sur le train uniquement.
- Pondération des classes pour le déséquilibre.
- Test indépendant pour comparer les modèles.

MODÈLES UTILISÉS

- Régression logistique.
- ToxNet : réseau feedforward.
- Arbre de décision.
- Entrée : 2048 bits Morgan.
- Forêt aléatoire.
- Couches : 512, 256, 128, 64.
- XGBoost.
- BatchNorm, ReLU, Dropout.
- LightGBM.
- Perte pondérée BCEWithLogits.
- SVM à noyau RBF.

RÉSULTATS ET PERFORMANCES

Meilleur ROC-AUC	Meilleur PR-AUC	Meilleur F1
0,911 SVM + Morgan	0,635 Random Forest	0,588 SVM




Figure. Comparaison globale des métriques pour les modèles entraînés.




Figure. Courbes ROC.




Figure. Courbes précision-rappel.

EXPLICABILITÉ ET INTERPRÉTATION

- SHAP relie la prédiction aux propriétés chimiques.
- Facteurs clés : LogP, BertzCT, TPSA.
- Molécules AhR souvent lipophiles et complexes.




Figure. Importance globale des caractéristiques par SHAP.

DEEP LEARNING – TOXNET

- Architecture dense pour empreintes Morgan.
- Early stopping contre le surapprentissage.
- ROC-AUC compétitif : 0,877.




Figure. Historique d'apprentissage de ToxNet.

TECHNOLOGIES UTILISÉES

- Python
- PyTorch
- RDKit
- SHAP
- NumPy / Pandas
- Matplotlib / Seaborn
- scikit-learn
- FastAPI
- XGBoost / LightGBM
- Streamlit

IMPACT / BÉNÉFICES

- Prioriser les molécules à tester en laboratoire.
- Réduire coûts et temps de criblage initial.
- Soutenir une toxicologie traçable et explicable.
- Prototype intégrable via API.

CONCLUSION / PERSPECTIVES

- Les empreintes Morgan donnent les meilleurs résultats.
- Le SVM offre le meilleur compromis ROC-AUC/F1.
- Validation externe nécessaire avant usage réglementaire.
- Perspectives : multi-tâches, GNN, incertitude.

CONTACT / ÉQUIPE PROJET

Étudiants ERFOUDI Anass JOUNAIDI Oussama	Institution Faculté des Sciences Ben M’Sick
Encadrante GUENDOUL Oumaima	Département Informatique
	Année universitaire 2025–2026