

Département Informatique

Prédiction de la Toxicité des Molécules Chimiques par Intelligence Artificielle

Dataset Tox21 – Machine Learning & Chimioinformatique

Réalisé par

ERFOUDI Anass
JOUNAIDI Oussama

Encadrante

GUENDOUL Oumaima

Rapport de Projet Master

Année universitaire 2025–2026

*Langages & Outils : Python, RDKit, scikit-learn, XGBoost, LightGBM, PyTorch,
SHAP, FastAPI, Streamlit*

Table des matières

1	Introduction	5
1.1	Contexte et motivation	5
1.2	Objectifs du projet	5
1.3	Organisation du rapport	6
2	État de l’art	7
2.1	Chimioinformatique et SMILES	7
2.2	Empreintes digitales moléculaires	7
2.3	Apprentissage automatique en chimioinformatique	7
2.4	Défi Tox21	8
3	Description du Jeu de Données	9
3.1	Présentation de Tox21	9
3.2	Caractéristiques du jeu de données	9
3.3	Téléchargement automatique	10
4	Méthodologie	11
4.1	Pipeline global	11
4.2	Gestion du déséquilibre de classes	11
4.3	Prévention de la fuite de données	12
5	Analyse Exploratoire des Données	13
5.1	Distribution des classes	13
5.2	Valeurs manquantes	13
5.3	Distribution des descripteurs	14
5.4	Matrice de corrélation	15
6	Ingénierie des Caractéristiques Moléculaires	16
6.1	Traitement RDKit	16
6.2	Descripteurs moléculaires	16
6.3	Empreintes Morgan (ECFP4)	17
6.4	Comparaison des types de caractéristiques	17

7	Modèles de Machine Learning	18
7.1	Modèles entraînés	18
7.1.1	Régression Logistique	18
7.1.2	Forêt Aléatoire	18
7.1.3	XGBoost	18
7.1.4	LightGBM	18
7.1.5	SVM	19
7.2	Validation croisée	19
8	Optimisation des Hyperparamètres	20
8.1	Stratégie d'optimisation	20
8.2	Pondération des classes	20
9	Résultats Expérimentaux	21
9.1	Métriques d'évaluation	21
9.2	Comparaison des modèles	21
9.3	Courbes ROC	22
9.4	Courbes Précision-Rappel	23
9.5	Matrices de confusion	23
9.6	Comparaison visuelle	24
9.7	Analyse critique des résultats	24
10	Deep Learning – ToxNet	25
10.1	Architecture ToxNet	25
10.2	Fonctions de perte et optimisation	25
10.3	Résultats ToxNet	26
11	Explicabilité par IA – SHAP	27
11.1	Introduction à SHAP	27
11.2	Importance globale des caractéristiques	28
11.3	Explication locale	29
11.4	Interprétation	29
12	Application Web	31
12.1	API FastAPI	31
12.2	Interface Streamlit	31
13	Discussion et Limitations	33
13.1	Analyse critique	33
13.2	Limitations	33

14 Conclusion et Perspectives	34
14.1 Conclusion	34
14.2 Perspectives	34
A Annexe A – Protocole Expérimental Détaillé	35
A.1 Environnement logiciel	35
A.2 Organisation des dossiers	35
A.3 Reproductibilité des expériences	36
A.4 Commandes de reproduction	36
B Annexe B – Interprétation Détaillée des Figures	37
B.1 Distribution des classes	37
B.2 Valeurs manquantes	37
B.3 Descripteurs moléculaires	37
B.4 Courbes ROC et PR	38
C Annexe C – Guide d’Utilisation de l’API et de l’Interface	39
C.1 API FastAPI	39
C.2 Interface Streamlit	39
D Annexe D – Plan de Tests et Assurance Qualité	40
D.1 Tests de données	40
D.2 Tests RDKit et feature engineering	40
D.3 Tests de modèles	40
D.4 Tests API	40
E Annexe E – Analyse Critique Complémentaire	42
E.1 Seuil de classification	42
E.2 Limites de l’approche 2D	42
E.3 Validation externe	42
E.4 Perspectives de recherche	43
F Annexe F – Fiches Techniques des Modèles	44
F.1 Régression logistique	44
F.2 Arbre de décision	44
F.3 Forêt aléatoire	44
F.4 XGBoost et LightGBM	45
F.5 Support Vector Machine	45
F.6 ToxNet	45
G Annexe G – Journal de Décision Scientifique	46

G.1	Choix de NR-AhR comme tâche principale	46
G.2	Choix des empreintes Morgan	46
G.3	Choix des descripteurs pour SHAP	46
G.4	Choix des métriques	47

Table des figures

5.1	Distribution des classes (taux de positivité et nombres) par essai Tox21	13
5.2	Pourcentage de valeurs manquantes par essai	13
5.3	Distributions des principaux descripteurs moléculaires	14
5.4	Boxplots des descripteurs moléculaires (détection des valeurs aberrantes)	14
5.5	Matrice de corrélation des descripteurs les plus variables	15
9.1	Courbes ROC de tous les modèles (tâche NR-AhR)	22
9.2	Courbes Précision-Rappel (tâche NR-AhR)	23
9.3	Matrices de confusion des modèles ML	23
9.4	Comparaison des métriques pour tous les modèles	24
10.1	Courbes d'apprentissage ToxNet (perte d'entraînement et ROC-AUC de validation)	26
11.1	SHAP Summary Plot – XGBoost sur descripteurs moléculaires	28
11.2	Importance globale SHAP (Mean SHAP value)	28
11.3	SHAP Waterfall Plot – explication d'une prédiction individuelle	29

Liste des tableaux

3.1	Description des 12 essais biologiques Tox21	9
6.1	Comparaison des types de caractéristiques	17
9.1	Comparaison des modèles sur l'essai NR-AhR (empreintes Morgan)	21

Chapitre 1

Introduction

1.1 Contexte et motivation

La toxicologie est une discipline fondamentale pour garantir la sécurité des médicaments, des pesticides, des cosmétiques et des additifs alimentaires. Avant qu'une molécule puisse être utilisée sur des êtres vivants, sa toxicité doit être rigoureusement évaluée. Les méthodes traditionnelles reposent sur des expériences en laboratoire et des tests sur animaux, qui sont :

- Très coûteux (1 à 3 millions de dollars par composé) ;
- Longs (plusieurs mois à plusieurs années) ;
- Limités en échelle ;
- Soulevés par des préoccupations éthiques concernant le bien-être animal.

L'intelligence artificielle, et en particulier l'apprentissage automatique, offre une alternative prometteuse pour prédire la toxicité directement à partir de la structure moléculaire.

1.2 Objectifs du projet

Ce projet vise à développer un système complet de prédiction de la toxicité moléculaire basé sur l'IA. Les objectifs spécifiques sont :

1. Télécharger et analyser le jeu de données Tox21 ;
2. Générer des représentations moléculaires (descripteurs et empreintes digitales) ;
3. Entraîner et comparer plusieurs modèles de machine learning ;

4. Développer un réseau de neurones profond (ToxNet) ;
5. Expliquer les prédictions avec SHAP ;
6. Déployer une API FastAPI et une interface Streamlit.

1.3 Organisation du rapport

Le rapport est structuré comme suit : le Chapitre 2 présente l'état de l'art, le Chapitre 3 décrit le jeu de données, les Chapitres 4 à 10 couvrent la méthodologie et les résultats, et les Chapitres 11–13 discutent l'application web, les limitations et les conclusions.

Chapitre 2

État de l'art

2.1 Chimioinformatique et SMILES

La chimioinformatique est un domaine interdisciplinaire qui combine la chimie, l'informatique et les statistiques pour analyser et modéliser les propriétés des molécules. La représentation SMILES (*Simplified Molecular-Input Line-Entry System*) est un format textuel standard permettant d'encoder la structure d'une molécule en une chaîne de caractères. Par exemple, l'éthanol est représenté par CCO et la caféine par Cn1c(=O)c2c(ncn2C)n(c1=O)C.

2.2 Empreintes digitales moléculaires

Les empreintes digitales moléculaires (fingerprints) sont des vecteurs binaires représentant la présence ou l'absence de sous-structures moléculaires :

- **Morgan/ECFP** : Empreintes circulaires capturant les sous-structures locales jusqu'à un rayon r . ECFP4 (rayon=2, 2048 bits) est le standard industriel [1].
- **MACCS Keys** : 167 clés représentant des groupes fonctionnels spécifiques ;
- **RDKit FP** : Empreintes topologiques basées sur les chemins moléculaires.

2.3 Apprentissage automatique en chimioinformatique

Les modèles de machine learning appliqués à la prédiction de toxicité incluent :

- **Forêts aléatoires** : Robustes, interprétables, efficaces sur des données tabulaires [2] ;

- **Gradient Boosting (XGBoost, LightGBM)** : Très performants sur les données moléculaires [3] ;
- **SVM** : Efficaces pour la classification binaire avec noyau RBF ;
- **Réseaux de neurones profonds** : Permettent d'apprendre des représentations hiérarchiques ;
- **Graph Neural Networks** : Traitent la molécule comme un graphe (atomes = noeuds, liaisons = arêtes).

2.4 Défi Tox21

Le défi Tox21 (2014–2015) était organisé par la FDA, NIEHS, NIH et EPA. L'objectif était de prédire les activités biologiques de 12 000 molécules sur 12 cibles toxicologiques. Les meilleures équipes ont obtenu des ROC-AUC de 0.88–0.93 [5].

Chapitre 3

Description du Jeu de Données

3.1 Présentation de Tox21

Le jeu de données Tox21 comprend 7831 molécules chimiques avec des annotations binaires (toxique/non-toxique) pour 12 essais biologiques :

Table 3.1: Description des 12 essais biologiques Tox21

Essai	Type	Description
NR-AR	Récepteur nucléaire	Récepteur aux androgènes
NR-AR-LBD	Récepteur nucléaire	Domaine de liaison du ligand
NR-AhR	Récepteur nucléaire	Récepteur aux hydrocarbures aromatiques
NR-Aromatase	Récepteur nucléaire	Aromatase
NR-ER	Récepteur nucléaire	Récepteur aux œstrogènes
NR-ER-LBD	Récepteur nucléaire	Domaine de liaison du ligand ER
NR-PPAR-gamma	Récepteur nucléaire	PPAR-gamma
SR-ARE	Réponse au stress	Élément de réponse antioxydante
SR-ATAD5	Réponse au stress	ATAD5
SR-HSE	Réponse au stress	Élément de réponse aux chocs thermiques
SR-MMP	Réponse au stress	Potentiel de membrane mitochondriale
SR-p53	Réponse au stress	Voie p53

3.2 Caractéristiques du jeu de données

- **7 831 molécules** au total (7823 valides après filtrage RDKit) ;
- **8 molécules invalides** éliminées (problèmes de valence) ;
- **Valeurs manquantes** : les molécules ne sont pas testées sur tous les essais ;
- **Déséquilibre de classes** : NR-AhR a 13.3% de positifs.

3.3 Téléchargement automatique

Les données sont téléchargées automatiquement depuis le CDN DeepChem :

Listing 3.1: Téléchargement du dataset Tox21

```
1 url = "https://deepchemdata.s3-us-west-1.amazonaws.com/datasets/tox21.csv.gz"
2 df = pd.read_csv(url, compression="gzip")
3 df.to_csv("data/raw/tox21.csv", index=False)
```

Chapitre 4

Méthodologie

4.1 Pipeline global

Le pipeline de ce projet suit les étapes suivantes :

1. Téléchargement et validation des données ;
2. Analyse exploratoire des données (EDA) ;
3. Traitement moléculaire avec RDKit ;
4. Génération des empreintes digitales ;
5. Pré-traitement et partitionnement des données ;
6. Entraînement des modèles ML classiques ;
7. Entraînement du réseau de neurones (ToxNet) ;
8. Optimisation des hyperparamètres ;
9. Évaluation et comparaison ;
10. Explicabilité avec SHAP.

4.2 Gestion du déséquilibre de classes

Le déséquilibre de classes est géré par :

- **Pondération des classes** : `class_weight='balanced'` dans scikit-learn ;
- `scale_pos_weight` dans XGBoost ($= n_{neg}/n_{pos}$) ;
- `WeightedRandomSampler` dans PyTorch ;
- `pos_weight` dans BCEWithLogitsLoss.

4.3 Prévention de la fuite de données

Pour éviter tout biais :

- Le préprocesseur est **fit** uniquement sur l'ensemble d'entraînement ;
- La validation croisée est effectuée après preprocessing ;
- Les ensembles train/test sont stratifiés.

Chapitre 5

Analyse Exploratoire des Données

5.1 Distribution des classes




Figure 5.1: Distribution des classes (taux de positivité et nombres) par essai Tox21

La Figure 5.1 montre un fort déséquilibre des classes. L'essai NR-AhR présente 13.3% de molécules toxiques (768 positifs, 5 774 négatifs).

5.2 Valeurs manquantes




Figure 5.2: Pourcentage de valeurs manquantes par essai

5.3 Distribution des descripteurs




Figure 5.3: Distributions des principaux descripteurs moléculaires




Figure 5.4: Boxplots des descripteurs moléculaires (détection des valeurs aberrantes)

5.4 Matrice de corrélation




Figure 5.5: Matrice de corrélation des descripteurs les plus variables

Chapitre 6

Ingénierie des Caractéristiques Moléculaires

6.1 Traitement RDKit

RDKit est une bibliothèque open-source de chimioinformatique. La conversion SMILES→mol permet d'extraire des propriétés moléculaires :

Listing 6.1: Conversion SMILES et calcul de descripteurs

```
1 from rdkit import Chem
2 from rdkit.Chem import Descriptors, rdMolDescriptors
3
4 mol = Chem.MolFromSmiles("CC(=O)Oc1ccccc1C(=O)O") # Aspirine
5 mw = Descriptors.MolWt(mol) # 180.16
6 logp = Descriptors.MolLogP(mol) # 1.19
7 tpsa = Descriptors.TPSA(mol) # 63.6 A^2
```

6.2 Descripteurs moléculaires

130 descripteurs ont été calculés, regroupant :

- **Propriétés Lipinski** : MW, LogP, TPSA, HBD, HBA, RotBonds ;
- **Descripteurs topologiques** : BertzCT, indices Chi, indices Kappa ;
- **Descripteurs VSA** : PEOE_VSA, SMR_VSA, SlogP_VSA ;
- **Indices électroniques** : MaxEStateIndex, MinEStateIndex ;
- **Fragments fonctionnels** : 80+ fragments RDKit (fr_halogen, fr_nitro, etc.) ;
- **QED** : Estimation de la drug-likeness quantitative.

6.3 Empreintes Morgan (ECFP4)

Les empreintes Morgan capturent les environnements atomiques circulaires :

$$fp_i^{(r)} = hash \left(\bigcup_{j \in \mathcal{N}_r(i)} fp_j^{(r-1)} \right) \quad (6.1)$$

où $\mathcal{N}_r(i)$ est le voisinage de rayon r autour de l'atome i . Avec $r = 2$ et $n = 2048$ bits, on obtient les empreintes ECFP4.

6.4 Comparaison des types de caractéristiques

Table 6.1: Comparaison des types de caractéristiques

Type	Dimension	ROC-AUC (RF)	Interprétabilité
Morgan FP (ECFP4)	2048	0.909	Faible
Descripteurs moléculaires	130	0.889	Haute
MACCS Keys	167	–	Moyenne

Chapitre 7

Modèles de Machine Learning

7.1 Modèles entraînés

Six modèles classiques ont été entraînés sur les empreintes Morgan :

7.1.1 Régression Logistique

Modèle linéaire pour la classification binaire :

$$P(y = 1|x) = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}} \quad (7.1)$$

Hyperparamètres : $C = 1.0$, solver=lbfgs, max_iter=1000.

7.1.2 Forêt Aléatoire

Ensemble de 200 arbres de décision. Chaque arbre est entraîné sur un sous-ensemble bootstrap des données avec sélection aléatoire des caractéristiques [2].

7.1.3 XGBoost

Gradient boosting avec régularisation L1/L2. 200 estimateurs, taux d'apprentissage = 0.1, profondeur max = 6 [3].

7.1.4 LightGBM

Variante efficace du gradient boosting avec histogram-based splitting. Plus rapide que XGBoost pour les grands jeux de données.

7.1.5 SVM

Machines à vecteurs de support avec noyau RBF :

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (7.2)$$

`C = 1.0, probability=True.`

7.2 Validation croisée

Une validation croisée stratifiée à 5 plis a été appliquée pour évaluer la généralisation :

$$\text{ROC-AUC}_{CV} = \frac{1}{K} \sum_{k=1}^K \text{ROC-AUC}_k \quad (7.3)$$

Chapitre 8

Optimisation des Hyperparamètres

8.1 Stratégie d’optimisation

Les hyperparamètres ont été sélectionnés par :

- Configuration manuelle basée sur la littérature ;
- Validation croisée 5-plis pour estimation robuste ;
- Partitionnement stratifié pour maintenir le ratio de classes ;
- Évaluation sur un ensemble de test indépendant (20%).

8.2 Pondération des classes

La pondération équilibrée est calculée comme :

$$w_c = \frac{n_{total}}{K \cdot n_c} \quad (8.1)$$

où K est le nombre de classes et n_c le nombre d’échantillons dans la classe c .

Pour NR-AhR : $w_0 = 0.566$, $w_1 = 4.261$.

Chapitre 9

Résultats Expérimentaux

9.1 Métriques d'évaluation

Les métriques utilisées sont :

- **Précision (Accuracy)** : $\frac{TP+TN}{TP+TN+FP+FN}$;
- **Précision (Precision)** : $\frac{TP}{TP+FP}$;
- **Rappel (Recall)** : $\frac{TP}{TP+FN}$;
- **F1-Score** : $\frac{2 \cdot P \cdot R}{P+R}$;
- **ROC-AUC** : Aire sous la courbe ROC ;
- **PR-AUC** : Aire sous la courbe Précision-Rappel.

9.2 Comparaison des modèles

Table 9.1: Comparaison des modèles sur l'essai NR-AhR (empreintes Morgan)

Modèle	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
SVM	0.8908	0.5285	0.6623	0.5879	0.9112	0.6032
RandomForest	0.9137	0.7531	0.3961	0.5191	0.9092	0.6351
XGBoost	0.8923	0.8095	0.1104	0.1943	0.8932	0.6144
LightGBM	0.8495	0.4207	0.7403	0.5365	0.8870	0.6174
LogisticRegression	0.8579	0.4339	0.6818	0.5303	0.8788	0.5706
DecisionTree	0.7502	0.2843	0.7403	0.4108	0.8017	0.3285

9.3 Courbes ROC




Figure 9.1: Courbes ROC de tous les modèles (tâche NR-AhR)

9.4 Courbes Précision-Rappel




Figure 9.2: Courbes Précision-Rappel (tâche NR-AhR)

9.5 Matrices de confusion




Figure 9.3: Matrices de confusion des modèles ML

9.6 Comparaison visuelle




Figure 9.4: Comparaison des métriques pour tous les modèles

9.7 Analyse critique des résultats

- Le **SVM** atteint le meilleur ROC-AUC (0.911) grâce au noyau RBF qui capture les relations non-linéaires dans l'espace des empreintes ;
- La **Forêt Aléatoire** offre le meilleur PR-AUC (0.635), plus pertinent pour les données déséquilibrées ;
- **XGBoost** a un F1 faible (0.194) dû à un seuil de classification non optimal ;
- Les **empreintes Morgan** surpassent les **descripteurs** (ROC-AUC 0.91 vs 0.89) ;
- La validation croisée confirme la stabilité (écart-type < 0.02 pour ROC-AUC).

Chapitre 10

Deep Learning – ToxNet

10.1 Architecture ToxNet

ToxNet est un réseau de neurones *feedforward* dédié à la prédiction de toxicité :

$$f(x) = W_5 \cdot \text{ReLU}(W_4 \cdot \text{BN}(\text{Drop}(\text{ReLU}(W_3 \cdot \dots)))) \quad (10.1)$$

Architecture : Entrée (2048) $\rightarrow$ BN $\rightarrow$ [512 $\rightarrow$ 256 $\rightarrow$ 128 $\rightarrow$ 64] $\rightarrow$ 1

Chaque couche cachée comprend : *Linear* + *BatchNorm1d* + *ReLU* + *Dropout*(0.3).

10.2 Fonctions de perte et optimisation

Perte : BCEWithLogitsLoss avec pos_weight :

$$\mathcal{L}(y, \hat{y}) = - [w_{pos} \cdot y \log \sigma(\hat{y}) + (1 - y) \log(1 - \sigma(\hat{y}))] \quad (10.2)$$

Optimiseur : Adam ($lr = 10^{-3}$, weight_decay = 10^{-4})

Scheduler : ReduceLROnPlateau (patience=5, factor=0.5)

10.3 Résultats ToxNet




Figure 10.1: Courbes d'apprentissage ToxNet (perte d'entraînement et ROC-AUC de validation)

ToxNet converge à l'époque 13 (early stopping) avec $\text{ROC-AUC} = 0.877$, $\text{F1} = 0.211$ et $\text{PR-AUC} = 0.559$.

Chapitre 11

Explicabilité par IA – SHAP

11.1 Introduction à SHAP

SHAP (*SHapley Additive exPlanations*) est une méthode unifiée d'interprétabilité basée sur la théorie des jeux. Pour un individu x , la valeur SHAP de la caractéristique j est [4] :

$$\phi_j(f, x) = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_{S \cup \{j\}}(x_{S \cup \{j\}}) - f_S(x_S)] \quad (11.1)$$

11.2 Importance globale des caractéristiques




Figure 11.1: SHAP Summary Plot – XGBoost sur descripteurs moléculaires




Figure 11.2: Importance globale SHAP (Mean |SHAP value|)

11.3 Explication locale




Figure 11.3: SHAP Waterfall Plot – explication d’une prédiction individuelle

11.4 Interprétation

Les principales caractéristiques identifiées par SHAP pour NR-AhR :

- **LogP** (liposolubilité) : valeurs élevées augmentent la toxicité ;
- **BertzCT** (complexité topologique) : molécules complexes plus toxiques ;
- **TPSA** (surface polaire) : valeurs faibles associées à la toxicité ;

- **Indices Kappa** : indicateurs de la forme moléculaire.

Ces résultats sont cohérents avec la biochimie du récepteur AhR, qui lie préférentiellement les molécules aromatiques lipophiles.

Chapitre 12

Application Web

12.1 API FastAPI

Une API RESTful a été développée avec FastAPI :

Listing 12.1: Endpoint de prédiction FastAPI

```
1 @app.post("/predict", response_model=PredictResponse)
2 def predict(request: PredictRequest):
3     X = smiles_to_features(request.smiles)
4     prob = float(model.predict_proba(X)[0][1])
5     return PredictResponse(
6         smiles=request.smiles,
7         toxic=(prob >= 0.5),
8         probability=round(prob, 4),
9         risk_level="HIGH" if prob >= 0.7 else "MEDIUM" if prob >= 0.4
10         else "LOW"
```

Endpoints disponibles :

- GET /health – Statut du service ;
- POST /predict – Prédiction pour un SMILES ;
- POST /batch_predict – Prédiction par lot ;
- GET /model_info – Informations sur le modèle ;
- GET /metrics – Métriques de performance.

12.2 Interface Streamlit

L'interface Streamlit offre :

- Saisie et visualisation moléculaire ;
- Prédiction en temps réel avec niveau de risque ;
- Comparaison visuelle des modèles ;
- Analyses SHAP interactives ;
- Tableau de bord analytique.

Chapitre 13

Discussion et Limitations

13.1 Analyse critique

Les résultats obtenus ($\text{ROC-AUC} \approx 0.91$) sont comparables à ceux des meilleures équipes du défi Tox21 original. La stratégie d'utilisation des empreintes Morgan s'avère supérieure aux descripteurs classiques, confirmant les travaux de [1].

13.2 Limitations

- **Spécificité des tâches** : Modèle entraîné sur NR-AhR uniquement ;
- **Apprentissage multi-tâches** : Non implémenté ;
- **Données 3D** : Conformation moléculaire non exploitée ;
- **Graph Neural Networks** : Non évalués ;
- **Validation externe** : Manque de jeux de données indépendants.

Chapitre 14

Conclusion et Perspectives

14.1 Conclusion

Ce projet démontre qu'il est possible de prédire la toxicité moléculaire avec une grande précision à partir de la seule structure SMILES. Les principaux résultats sont :

- **Meilleur modèle** : SVM avec empreintes Morgan (ROC-AUC = 0.911) ;
- **Pipeline complet** : Du téléchargement des données à l'API de production ;
- **Explicabilité** : SHAP identifie LogP, BertzCT, TPSA comme facteurs clés ;
- **Robustesse** : 28 tests automatiques réussis et 1 test ignoré.

14.2 Perspectives

- Implémentation de Graph Neural Networks (GCN/MPNN) ;
- Apprentissage multi-tâches sur les 12 essais Tox21 ;
- Modèles de langage moléculaires (ChemBERTa, MolBERT) ;
- Quantification de l'incertitude (Dropout de Monte Carlo) ;
- Déploiement en production avec Docker et Kubernetes ;
- Intégration dans des pipelines de criblage virtuel.

Annexe A

Annexe A – Protocole Expérimental Détaillé

A.1 Environnement logiciel

Cette annexe décrit les choix d'implémentation permettant de reproduire les résultats. Le projet repose sur Python 3.11 et sur des bibliothèques standards de science des données et de chimioinformatique. RDKit est utilisé pour le parsing SMILES, le calcul des descripteurs, les empreintes Morgan, les MACCS keys et les empreintes topologiques. Scikit-learn fournit les modèles classiques, les métriques, la validation croisée et les stratégies de prétraitement. XGBoost et LightGBM sont utilisés pour les modèles de boosting, PyTorch pour le réseau ToxNet, SHAP pour l'explicabilité, FastAPI pour l'API et Streamlit pour l'interface graphique.

A.2 Organisation des dossiers

Dossier	Rôle
<code>data/raw</code>	Données originales Tox21 en CSV et archive compressée.
<code>data/processed</code>	Tableaux NumPy et CSV issus du parsing RDKit et du split train/test.
<code>src</code>	Code source du pipeline, des modèles, de l'explicabilité et de la génération des livrables.
<code>models</code>	Modèles entraînés en <code>.pkl</code> et réseau ToxNet en <code>.pt</code> .
<code>reports</code>	Métriques, figures, journal d'exécution et présentation PowerPoint.
<code>api</code>	Service FastAPI de prédiction.

<code>webapp</code>	Interface Streamlit démonstrative.
<code>tests</code>	Tests automatisés du pipeline et de l'API.
<code>latex</code>	Rapport académique et figures copiées pour compilation.

A.3 Reproductibilité des expériences

La reproductibilité est assurée par une séparation stricte entre les données brutes, les matrices de caractéristiques et les artefacts de sortie. Le pipeline applique un partitionnement stratifié afin de conserver la proportion de molécules toxiques et non toxiques dans les ensembles d'entraînement et de test. Les prétraitements sont ajustés uniquement sur l'ensemble d'entraînement, puis appliqués sur l'ensemble de test. Cette stratégie limite les fuites de données et permet une comparaison plus fiable des modèles.

A.4 Commandes de reproduction

Listing A.1: Execution complete du pipeline

```
1 python src/pipeline.py
2 python src/generate_latex.py
3 python src/generate_presentation.py
4 pytest -q
```

Annexe B

Annexe B – Interprétation Détaillée des Figures

B.1 Distribution des classes

La distribution des classes montre que les essais Tox21 sont fortement déséquilibrés. Pour NR-AhR, la classe positive représente 13.3% des molécules labelisées. Cela signifie qu’une accuracy élevée ne suffit pas à juger la qualité du modèle: un classifieur trivial qui prédit toujours la classe majoritaire obtiendrait une accuracy importante tout en étant inutile pour la détection de toxicité. Pour cette raison, les métriques ROC-AUC, PR-AUC, rappel et F1 sont analysées en parallèle.

B.2 Valeurs manquantes

Les valeurs manquantes proviennent du fait que toutes les molécules ne sont pas testées sur tous les essais biologiques. Le pipeline choisit une tâche cible principale, NR-AhR, puis conserve uniquement les molécules labelisées pour cette tâche lors de l’entraînement. Cette approche évite d’imputer artificiellement des labels biologiques absents.

B.3 Descripteurs moléculaires

Les histogrammes et boxplots des descripteurs montrent des distributions asymétriques. Les propriétés comme la masse moléculaire, la complexité topologique et le LogP présentent des queues longues, ce qui est typique des banques chimiques. L’utilisation d’un scaler robuste et d’une imputation adaptée est donc justifiée pour les modèles sensibles à l’échelle des variables.

B.4 Courbes ROC et PR

La courbe ROC mesure la capacité de classement globale entre positifs et négatifs. La courbe précision-rappel est plus exigeante en contexte déséquilibré, car elle se concentre sur la classe positive. RandomForest présente le meilleur PR-AUC, tandis que SVM obtient le meilleur ROC-AUC. Cette différence illustre qu'un seul indicateur ne peut pas résumer tous les besoins toxicologiques.

Annexe C

Annexe C – Guide d’Utilisation de l’API et de l’Interface

C.1 API FastAPI

L’API expose cinq endpoints. `/health` permet de vérifier que le service fonctionne et que le modèle est chargé. `/predict` accepte une chaîne SMILES et retourne une probabilité de toxicité, un booléen `toxic` et un niveau de risque. `/batch_predict` applique la même logique à une liste de molécules. `/model_info` décrit le modèle utilisé et `/metrics` expose les performances enregistrées.

Listing C.1: Exemple de lancement de l’API

```
1 uvicorn api.main:app --reload --host 127.0.0.1 --port 8000
```

Listing C.2: Exemple de requete JSON

```
1 {  
2   "smiles": "CC(=O)Oc1ccccc1C(=O)O"  
3 }
```

C.2 Interface Streamlit

L’interface Streamlit permet à un utilisateur non spécialiste de saisir une molécule, de visualiser sa structure, d’obtenir une prédiction, puis de consulter les comparaisons de modèles et les explications SHAP. Elle constitue une couche de démonstration adaptée à une soutenance académique.

Listing C.3: Exemple de lancement de l’interface

```
1 streamlit run webapp/app.py
```

Annexe D

Annexe D – Plan de Tests et Assurance Qualité

D.1 Tests de données

Les tests vérifient la présence du fichier Tox21 brut, la taille minimale du jeu de données, la présence de la colonne SMILES et la disponibilité des tâches toxicologiques principales. Ces tests assurent que le pipeline ne s'exécute pas sur une source de données incomplète.

D.2 Tests RDKit et feature engineering

Les tests RDKit valident le parsing des SMILES corrects, le rejet des SMILES invalides, le calcul des descripteurs, la taille des empreintes Morgan et la taille des MACCS keys. Ces contrôles sont essentiels, car une erreur silencieuse dans la vectorisation moléculaire contaminerait l'ensemble de l'expérience.

D.3 Tests de modèles

Les tests chargent un modèle sauvegardé, vérifient la présence de `predict_proba`, la forme des probabilités retournées et leur appartenance à l'intervalle $[0, 1]$. Ils valident aussi un exemple end-to-end depuis un SMILES jusqu'à une probabilité de toxicité.

D.4 Tests API

Les tests FastAPI utilisent un client de test local. Ils couvrent les endpoints `/health`, `/predict`, `/metrics` et `/model_info`. Les SMILES invalides sont gérés explicitement

afin d'éviter des erreurs serveur non contrôlées.

Annexe E

Annexe E – Analyse Critique Complémentaire

E.1 Seuil de classification

Les métriques de classification dépendent du seuil utilisé pour convertir une probabilité en classe. Le seuil par défaut de 0.5 peut être sous-optimal en toxicologie. Dans un contexte de criblage, on peut privilégier un seuil plus faible pour augmenter le rappel et réduire le nombre de molécules toxiques manquées. Dans un contexte de priorisation de tests coûteux, on peut au contraire augmenter le seuil pour améliorer la précision.

E.2 Limites de l’approche 2D

Les empreintes Morgan et les descripteurs RDKit utilisés ici capturent principalement des informations 2D. Certaines toxicités dépendent toutefois de conformations 3D, d’interactions protéine-ligand, de métabolites et de conditions expérimentales. Le modèle doit donc être interprété comme un système de priorisation *in silico*, non comme un substitut complet aux validations biologiques.

E.3 Validation externe

Une validation externe sur un jeu indépendant serait nécessaire avant une utilisation réglementaire. Elle permettrait d’évaluer la robustesse du modèle face à des molécules provenant d’un espace chimique différent. Cette étape est particulièrement importante pour limiter le risque de sur-optimisation sur Tox21.

E.4 Perspectives de recherche

Les extensions les plus prometteuses sont l'apprentissage multi-tâches, les Graph Neural Networks, les modèles de langage moléculaires et la quantification d'incertitude. L'apprentissage multi-tâches peut exploiter les corrélations entre essais Tox21. Les GNN permettent de traiter directement le graphe moléculaire. Les modèles de langage moléculaires capturent des représentations apprises à grande échelle. Enfin, l'incertitude est essentielle pour signaler les prédictions hors domaine.

Annexe F

Annexe F – Fiches Techniques des Modèles

F.1 Régression logistique

La régression logistique constitue une base de comparaison linéaire. Elle modélise la probabilité de toxicité par une fonction sigmoïde appliquée à une combinaison pondérée des caractéristiques. Son intérêt principal est la simplicité: elle permet de vérifier si une frontière linéaire dans l'espace des empreintes Morgan suffit à distinguer les molécules actives et inactives. Dans ce projet, elle atteint un ROC-AUC de 0.8788, ce qui montre qu'une part importante du signal est déjà capturable par une structure relativement simple.

F.2 Arbre de décision

L'arbre de décision segmente l'espace des caractéristiques par une suite de règles binaires. Il est interprétable mais sensible au surapprentissage, surtout avec des empreintes binaires de grande dimension. Ses performances plus faibles confirment que la toxicité NR-AhR ne se réduit pas à quelques règles simples et stables.

F.3 Forêt aléatoire

La forêt aléatoire agrège de nombreux arbres entraînés sur des sous-échantillons et des sous-ensembles de variables. Elle réduit la variance de l'arbre unique et s'adapte bien aux empreintes moléculaires. Dans les résultats obtenus, elle présente le meilleur PR-AUC, ce qui est particulièrement utile pour les données déséquilibrées.

F.4 XGBoost et LightGBM

Les modèles de gradient boosting construisent une séquence d'arbres faibles, chacun corrigeant les erreurs du précédent. XGBoost est robuste et efficace sur des données tabulaires complexes; LightGBM optimise la vitesse et la gestion de grands ensembles de variables. Les deux modèles sont performants en ROC-AUC, mais XGBoost présente un F1 faible avec le seuil par défaut, ce qui souligne l'importance du calibrage de seuil.

F.5 Support Vector Machine

Le SVM à noyau RBF obtient le meilleur ROC-AUC. Le noyau RBF projette implicitement les données dans un espace non linéaire, ce qui permet de capturer des relations complexes entre fragments chimiques et toxicité. Son principal inconvénient est son coût computationnel plus élevé, observé pendant l'entraînement et la validation croisée.

F.6 ToxNet

ToxNet est un réseau feedforward appliqué aux empreintes Morgan. Le modèle utilise BatchNorm, Dropout et une perte pondérée pour gérer l'instabilité et le déséquilibre de classes. Son ROC-AUC reste compétitif, mais son F1 est faible avec le seuil de classification retenu. Une optimisation du seuil, davantage d'époques ou une architecture multi-tâches pourraient améliorer ses performances pratiques.

Annexe G

Annexe G – Journal de Décision Scientifique

G.1 Choix de NR-AhR comme tâche principale

NR-AhR a été retenue comme tâche principale car elle possède un nombre suffisant d'échantillons labelisés et un intérêt toxicologique clair. Le récepteur AhR est associé à des hydrocarbures aromatiques et à des mécanismes de réponse cellulaire pertinents pour l'évaluation du risque chimique.

G.2 Choix des empreintes Morgan

Les empreintes Morgan sont largement utilisées en chimioinformatique car elles encodent les sous-structures locales autour de chaque atome. Elles sont adaptées aux modèles classiques et permettent de comparer efficacement les molécules sans exiger une conformation 3D. Les résultats confirment leur pertinence: les meilleurs scores sont obtenus avec les empreintes Morgan plutôt qu'avec les seuls descripteurs physico-chimiques.

G.3 Choix des descripteurs pour SHAP

Les fingerprints binaires sont efficaces mais difficiles à interpréter chimiquement, car chaque bit correspond à un motif haché. Les descripteurs RDKit sont donc utilisés pour les explications SHAP les plus lisibles. Des variables comme LogP, TPSA et BertzCT permettent une discussion scientifique plus naturelle sur la lipophilie, la polarité et la complexité moléculaire.

G.4 Choix des métriques

Le projet rapporte accuracy, precision, recall, F1, ROC-AUC et PR-AUC. Cette pluralité est nécessaire car les objectifs peuvent varier. Pour un système de filtrage précoce, le rappel est critique afin de ne pas manquer des molécules dangereuses. Pour un système de priorisation expérimentale, la précision devient plus importante afin de limiter les faux positifs coûteux.

Bibliographie

- [1] Rogers, D., & Hahn, M. (2010). *Extended-Connectivity Fingerprints*. Journal of Chemical Information and Modeling, 50(5), 742–754.
- [2] Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.
- [3] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. KDD 2016, 785–794.
- [4] Lundberg, S. M., & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. NIPS 2017, 4765–4774.
- [5] Huang, R., et al. (2016). *Tox21 Challenge to Build Predictive Models of Nuclear Receptor and Stress Response Pathways as Mediated by Exposure to Environmental Chemicals and Drugs*. Frontiers in Environmental Science.
- [6] Landrum, G. (2023). *RDKit: Open-Source Cheminformatics*. <http://www.rdkit.org>
- [7] Wu, Z., et al. (2018). *MoleculeNet: A Benchmark for Molecular Machine Learning*. Chemical Science, 9(2), 513–530.
- [8] Ramsundar, B., et al. (2019). *Deep Learning for the Life Sciences*. O’Reilly Media.